

Aula 6: A rede que decora — sobreajuste, regularização e generalização

Viés e variância • validação • dropout • weight decay

Prof. Marcelo Keese Albertini

GBC073 — Inteligência Computacional • Universidade Federal de Uberlândia
2026



- ▶ **O sobreajuste e o dilema viés-variância**

- ▶ **O sobreajuste e o dilema viés-variância**
- ▶ **Validação, early stopping e conjunto de teste**

- ▶ **O sobreajuste e o dilema viés-variância**
- ▶ **Validação, early stopping e conjunto de teste**
- ▶ **Regularização explícita:** weight decay e dropout

- ▶ **O sobreajuste e o dilema viés-variância**
- ▶ **Validação, early stopping e conjunto de teste**
- ▶ **Regularização explícita:** weight decay e dropout
- ▶ **Normalização e aumento de dados**

PARTE 1

O sobreajuste e o dilema viés-variância



- ▶ Sobreajuste (*overfitting*): decorar o conjunto de treino e falhar no que não viu.
- ▶ Erro de generalização = viés (modelo simples demais) + variância (modelo sensível demais ao sorteio dos dados) + ruído.
- ▶ Redes grandes têm variância alta — daí a fama de “decorar”.
- ▶ Mas redes grandes *com* regularização costumam generalizar melhor (contra-intuição importante).

PARTE 2

Validação, early stopping e conjunto de teste



- ▶ Três partições: treino (ajusta), validação (decide), teste (relata — só uma vez).
- ▶ *Early stopping*: parar quando o erro de validação para de cair.
- ▶ Escolher hiperparâmetros pelo teste vaza o teste — vício sutil.
- ▶ Curvas de aprendizado como ferramenta de diagnóstico.

PARTE 3

Regularização explícita



- ▶ Weight decay (L_2 nos pesos): penaliza pesos grandes, encolhe para soluções simples.
- ▶ Dropout: sorteia neurônios desligados a cada passo — a rede aprende a ser redundante.
- ▶ Dropout como *ensemble* barato: média implícita de muitas redes.
- ▶ Em teste, nada é desligado (ou se re-escala a ativação).

Intuição

Regularizar não é castigar a rede — é impedir que ela memorize o que não deveria existir como regra.

PARTE 4

Normalização e aumento de dados



- ▶ Normalização de lote (*batch norm*): estabiliza a distribuição das ativações — treina mais rápido e regulariza de brinde.
- ▶ Aumento de dados (*data augmentation*): fabricar exemplos plausíveis (rotações, ruído, recortes).
- ▶ A regularização mais barata costuma ser mais dados — reais ou sintéticos.