

# Aula 9: Atenção — quando a rede aprende onde olhar

---

Self-attention • transformers • LLMs • o custo da escala

**Prof. Marcelo Keese Albertini**

GBC073 — Inteligência Computacional • Universidade Federal de Uberlândia  
2026



- ▶ **Atenção como média ponderada aprendida**

- ▶ **Atenção como média ponderada aprendida**
- ▶ **Self-attention: cada token olha todos os outros**

- ▶ **Atenção como média ponderada aprendida**
- ▶ **Self-attention: cada token olha todos os outros**
- ▶ **O transformer**

- ▶ **Atenção como média ponderada aprendida**
- ▶ **Self-attention: cada token olha todos os outros**
- ▶ **O transformer**
- ▶ **LLMs e o custo da escala**

## PARTE 1

# Atenção como média ponderada aprendida

---



- ▶ Na RNN, o passado inteiro precisa caber num único vetor de estado — gargalo.
- ▶ Atenção: a saída olha diretamente para todas as posições e decide o peso de cada uma.
- ▶ Consulta (*query*), chave (*key*) e valor (*value*): a tríade da atenção.
- ▶ Os pesos de atenção são aprendidos — a rede aprende *onde olhar*.

## PARTE 2

# Self-attention

---





## Self-attention: cada token olha todos os outros

- ▶ Uma sequência olha para si mesma: cada token pondera todos os demais, incluindo ele próprio.
- ▶ Caminho de informação de comprimento constante entre qualquer par de posições.
- ▶ Multi-cabeças: várias relações em paralelo (sintaxe, gênero, co-referência...).
- ▶ Codificação posicional: sem recorrência, a ordem precisa ser injetada.

## PARTE 3

# 0 transformer

---



- ▶ Blocos repetidos: atenção + rede densa, com conexões residuais e normalização.
- ▶ Codificador-decodificador: tradução e afins.
- ▶ Só-decodificador: os modelos de linguagem modernos.
- ▶ Paralelismo total no treino — é a arquitetura que escala.

## PARTE 4

# LLMs e o custo da escala

---



- ▶ Leis de escala: capacidade emerge com dados e computação juntos.
- ▶ Pré-treino em corpora imensos + ajuste fino para tarefas.
- ▶ O custo da escala: energia, dinheiro e a concentração de quem pode treinar.
- ▶ A revanche da aula 1: o perceptron, 65 anos depois.

## Para discutir em aula

O custo computacional do self-attention cresce linearmente com o comprimento da sequência.

*Verdadeiro / Falso*